

DIFE 및 LS-SWAP 양자 오토인코더 전략에 대한 기술 평가 보고서

Executive Summary

본 보고서는 DIFE(Destructive Interference Fidelity Estimation)와 LS-SWAP(Latent Space SWAP Test)이라는 두 가지 새로운 양자 오토인코더(QAE) 전략에 대한 심층적인 기술 평가를 제공합니다. 분석 결과, 두 방법 모두 이론적으로 타당하며 명시된 사양에 따라 기술적으로 구현 가능성이 확인되었습니다.

보고서의 핵심 발견은 두 접근 방식 사이에 존재하는 중대한 이분법입니다. DIFE는 재구성 충실도에 대한 직접적이고 완전하며 우아한 측정 방법을 제공하지만, 전역 비용 함수(global cost function)와 관련된 "황무지 평원(barren plateau)" 현상으로 인해 대규모 시스템에서 훈련 불가능성의 높은 위험에 직면합니다. 반면, LS-SWAP은 자원 효율적인 국소적 대리 충실도(local proxy fidelity)를 사용하여 훈련 가능성을 크게 향상시키고 황무지 평원 현상을 완화할 것으로 예상되지만, 이는 전체 상태의 실제 재구성 충실도를 직접 측정하지 않는다는 대가를 치릅니다. 결론적으로 DIFE와 LS-SWAP 사이의 선택은 정확성의 문제가 아니라 전략적 결정의 문제입니다. DIFE는 측정의 순수성이 가장 중요한 소규모 개념 증명(proof-of-concept) 구현에 적합합니다. 반면, LS-SWAP은 훈련 가능성이 현실적인 필수 요건인 확장 가능한 QAE 개발에 권장되는 경로입니다. 두 전략을 모두 구현하고, 예측된 확장성 차이를 검증하기 위한 체계적인 실험적 연구를 수행할 것을 제안합니다.

1. DIFE (Destructive Interference Fidelity Estimation)

전략 분석

본 섹션에서는 DIFE 방법론을 해부하여 이론적 타당성과 구현 가능성을 확립하고, 이 방법이 직면한 가장 중요한 과제인 대규모 시스템에서의 훈련 가능성에 대한 비판적 분석을 제시합니다.

1.1. 이론적 기반: Compute-Uncompute 원리

DIFE 전략의 핵심은 "compute-uncompute" 방법론에 기반합니다. 이 원리는 양자 시스템을 특정 초기 상태(일반적으로 $|0\rangle^{\otimes n}$)에서 시작하여 유니터리 연산 U 를 통해 진화시킨 후, 즉시 해당 연산의 에르미트 켤레(Hermitian conjugate)인 $U^\dagger$ 를 적용하는 과정을 포함합니다. 따라서 전체 시스템의 진화는 $U^\dagger U$ 로 표현됩니다.

이 과정에서 양자 간섭 현상이 결정적인 역할을 합니다.¹ 만약 유니터리 연산 U 가 완벽하게 구현되고 시스템이 양자 결맞음(coherence)을 유지한다면, $U^\dagger U = I$ (항등 연산자)가 되어 시스템은 정확히 초기 상태인 $|0\rangle^{\otimes n}$ 으로 되돌아갑니다. 이는 완벽한 보강 간섭(constructive interference)의 결과입니다. 반면, 오토인코더의 불완전한 재구정으로 인해 상태 진화 과정에서 발생하는 모든 오차나 편차는 최종 상태가 초기 상태 $|0\rangle^{\otimes n}$

n)\$에서 벗어나게 만듭니다. 이는 상쇄 간섭(destructive interference) 현상에 기인합니다.¹ 따라서 이 과정의 충실도(fidelity)는 최종 상태가 초기 상태 $|0\rangle^{\otimes n}$ 에 있을 확률을 측정함으로써 정량화할 수 있습니다. 이 확률은 $|\langle 0|U^\dagger U|\psi_{in}\rangle|^2$ 로 주어지며, 초기 상태가 $|\psi_{in}\rangle = |0\rangle$ 인 경우, 이는 사영 연산자(projector) $|0\rangle\langle 0|$ 의 기댓값과 동일합니다. 측정된 확률이 1에 가까울수록 완벽한 재구성을 의미합니다.

1.2. 양자 정보 과학에서의 타당성 및 선행 연구

Compute-uncompute 방법은 새로운 발명이 아니라 양자 컴퓨팅 분야에서 충실도 추정을 위해 널리 사용되는 표준 기술입니다. 이 방법의 타당성은 주요 양자 소프트웨어 프레임워크에 핵심 구성 요소로 포함되어 있다는 사실에서 확인할 수 있습니다.

- **Qiskit 구현:** IBM의 Qiskit 라이브러리는 `qiskit.algorithms.state_fidelities.ComputeUncompute`라는 전용 클래스를 제공하여 이 방법을 명시적으로 구현합니다. 이 클래스는 ψ 를 준비하는 회로와 ϕ 를 준비하는 회로의 역(inverse)을 결합하여 상태 중첩(overlap)인 $|\langle \psi(x)|\phi(y)\rangle|^2$ 를 계산하는 충실도 회로를 생성합니다.³ 이는 DIFE 명세서에서 인코더 U_{enc} 와 그 에르미트 켤레 $U_{enc}^\dagger$ 를 사용하는 방식과 정확히 일치합니다.
- **보조 큐비트 불필요 (Ancilla-Free):** 이 방법의 핵심 장점 중 하나는 표준 SWAP 테스트와 달리 추가적인 보조 큐비트(ancilla qubit)를 필요로 하지 않는다는 점입니다. 이는 큐비트 수 측면에서 자원 효율적인 선택이 되게 합니다.⁶ DIFE 명세서는 이 특성을 정확하게 활용하고 있습니다.
- **학술적 맥락:** Compute-uncompute 방법은 학술 문헌에서도 충실도를 직접적으로 계산하는 방법으로 언급되며, 특히 보조 큐비트나 장거리 게이트(long-ranged gate)를 피하는 것이 유리한 회로 니팅(circuit knitting)과 같은 맥락에서 유용하게 사용됩니다.⁶ 또한, 더 진보된 변분 양자 알고리즘(variational quantum algorithm)의 구성 요소로도 활용됩니다.¹⁰

1.3. PennyLane에서의 구현 가능성 평가

PennyLane 라이브러리를 사용한 DIFE 회로의 구현은 전적으로 실현 가능하며, 라이브러리가 제공하는 핵심 기능들을 활용합니다.

- **핵심 함수:**
 - `qml.adjoint(encoder_ansatz)`: PennyLane의 `qml.adjoint` 함수는 사용자 정의 함수나 템플릿에 적용되도록 명시적으로 설계되었습니다.¹¹ 이 함수는 `encoder_ansatz`의 에르미트 켤레를 정확하게 구성하며, 안사츠 내의 각 게이트의 에르미트 켤레를 역순으로 적용합니다. 이는 DIFE 명세서의 "uncompute" 요구사항과 완벽하게 부합합니다.
 - `qml.Projector`: `qml.Projector` 관측량(observable)은 시스템이 모든 큐비트가 0인 상태, 즉 $|0\dots 0\rangle$ 상태에 있을 확률을 측정하기 위한 올바른 도구입니다.¹³ 명세서에서 제안된 측정 방식인 `qml.expval(qml.Projector(*n_data_qubits, wires=range(n_data_qubits)))`는

충실도 값인 $|\langle 0 \dots 0 | \psi_{final} \rangle|^2$ 를 정확하게 반환할 것입니다.

- 구현 가능성 결론: 명세서에 기술된 **dife_circuit**을 구현하는 데 있어 어떠한 기술적 장벽도 확인되지 않았습니다. PennyLane 라이브러리는 **compute-uncompute** 로직을 직접적이고 효율적으로 실현하는 데 필요한 모든 기본 요소를 제공합니다.

1.4. 비판적 평가: 전역 비용 함수와 황무지 평원으로 인한 확장성 위험

DIFE 전략의 가장 심각한 잠재적 문제는 훈련 가능성, 특히 시스템 규모가 커질 때 발생할 수 있는 황무지 평원(**barren plateau**) 현상입니다.

- **DIFE** 비용 함수의 정의: DIFE의 비용 함수 $C = 1.0 - \text{fidelity}$ 는 사영 연산자 $|0 \dots 0\rangle\langle 0 \dots 0|$ 의 기댓값에 의존합니다. 이 사영 연산자는 측정 결과가 시스템의 모든 n_data_qubits 의 집합적 상태에 따라 결정되기 때문에 전역 관측량(**global observable**)에 해당합니다.
- 황무지 평원 현상: 변분 양자 알고리즘은 매개변수 공간에서 비용 함수의 기울기(**gradient**)가 큐비트 수에 따라 지수적으로 사라지는 "황무지 평원"으로 인해 어려움을 겪는 것으로 알려져 있습니다.¹⁴ 이 현상이 발생하면 기울기 기반 최적화 방법이 효과를 잃게 되어, 대규모 시스템에서는 알고리즘의 훈련이 사실상 불가능해집니다.
- 전역 비용 함수와 황무지 평원의 연관성: 변분 양자 알고리즘 연구의 핵심적인 발견 중 하나는 전역 비용 함수의 사용과 황무지 평원 발생 사이에 직접적인 인과 관계가 있다는 것입니다.
 - 이론적 증명: **Cerezo** 등의 연구는 전역 관측량으로 정의된 비용 함수가 얕은(**shallow**) 양자 회로에서도 기울기가 지수적으로 사라지는 현상을 초래한다는 것을 수학적으로 엄밀하게 증명했습니다.¹⁶ DIFE의 비용 함수는 이 연구에서 분석된 전역 비용 함수의 전형적인 예시입니다. 특히, $C_G = 1 - p_{|00\dots 0\rangle}$ 형태의 비용 함수는 황무지 평원의 원인으로 명확히 지목됩니다.¹⁴
 - 수치적 증거: 동일한 연구에서는 최대 100큐비트 규모의 양자 오토인코더에 대한 대규모 시뮬레이션 결과를 제시하며, 전역 비용 함수를 사용했을 때 큐비트 수가 증가함에 따라 훈련이 불가능해지는 반면, 국소적(**local**) 비용 함수를 사용했을 때는 훈련이 가능함을 실험적으로 보여주었습니다.¹⁸

이러한 분석은 DIFE 전략의 근본적인 딜레마를 드러냅니다. DIFE의 가장 큰 장점, 즉 보조 큐비트 없이 재구성 충실도를 직접적이고 완전하게 측정할 수 있다는 점이 역설적으로 가장 큰 약점의 원인이 됩니다. 이 순수한 측정 방식의 "전역적" 특성이 바로 이론적으로 알고리즘을 대규모 시스템에서 훈련 불가능하게 만들 것이라고 예측되는 이유입니다. 훈련 가능한 알고리즘을 설계하기 위해서는 비용 함수가 필요하고, 효과적인 최적화 과정이 수반되어야 합니다. DIFE가 제안하는 비용 함수는 재구성 충실도를 완벽하게 측정하지만, 변분 양자 알고리즘의 훈련 가능성에 대한 연구는 비용 함수를 구성하는 관측량의 *국소성(**locality**)*이 알고리즘의 훈련 가능성을 결정한다는 중요한 원칙을 확립했습니다. DIFE의 비용 함수는 비국소적인 전역 사영 연산자에 의존하므로, 큐비트 수가 증가함에 따라 기울기가 지수적으로 사라질 가능성이 매우 높습니다. 이는 "완벽한" 충실도 측정 기준을 추구하는 것이 "훈련 가능한" 알고리즘이라는 실용적 요구사항과 직접적으로 충돌한다는 심오한 결론으로 이어집니다. 따라서 DIFE 명세서는 기술적으로는 타당하지만, 변분 양자 알고리즘 설계에서 가장 중요한 성능 상충 관계(**trade-off**) 중 하나를 간과하고 있습니다.

2. LS-SWAP (Latent Space SWAP Test) 전략 분석

본 섹션에서는 LS-SWAP 방법론을 평가합니다. 이 방법은 기존 QAE 훈련 패러다임의 논리적이고 자원 효율적인 변형으로, 특히 DIFE 전략에서 확인된 훈련 가능성 문제에 대한 강력한 해결책을 제시하는 관점에서 분석을 집중합니다.

2.1. 이론적 기반: 부분 공간 충실도를 대리 측정 기준으로 활용

LS-SWAP 전략은 전체 $n_{\text{data_qubits}}$ 상태의 충실도를 측정하는 대신, 압축된 잠재 공간(latent space)을 구성하는 n_{latent} 큐비트에 대해서만 SWAP 테스트를 수행합니다.

- **SWAP 테스트:** SWAP 테스트는 두 양자 상태 $|\psi\rangle$ 와 $|\phi\rangle$ 사이의 충실도, 즉 중첩의 제공 값을 측정하기 위한 표준적인 양자 서브루틴입니다. 이 테스트는 제어 큐비트(control qubit)와 제어된-SWAP(controlled-SWAP) 게이트를 사용하며, 제어 큐비트에 대한 파울리

Z 연산자의 기댓값($\langle Z \rangle$)은 충실도 F 와 직접적인 관계를 가집니다:

$$F(|\psi\rangle, |\phi\rangle) = \frac{\langle Z \rangle + 1}{2}.$$

- **핵심 가정 (대리 측정 기준):** LS-SWAP 방법은 "압축된 잠재 상태의 충실도가 전체 시스템의 충실도를 나타내는 충분한 대리 지표(proxy)"라는 중요한 가정 하에 작동합니다. 즉, 이 훈련 과정은 잠재 공간의 완벽한 재구성을 목표로 최적화를 수행하며, 이것이 전체 상태의 양호한 재구성으로 이어질 것이라고 가정합니다. 이는 발견적(heuristic) 접근법이지만, 오토인코더의 기본 논리에 근거합니다. 오토인코더의 목표는 모든 관련 정보를 잠재 공간 내에 보존하는 것이므로¹⁹, 잠재 공간이 올바르게 재구성되었는지 확인하는 것은 논리적이지만 간접적인 목표 설정 방식입니다.

2.2. 양자 오토인코더 문헌에서의 타당성 및 선행 연구

LS-SWAP 접근법은 기존 QAE 훈련 패러다임의 새로운 변형입니다. Romero 등이 발표한 QAE에 관한 기초 연구에서는 인코딩 후 버려지는 "쓰레기(trash)" 큐비트와 알려진 참조 상태(예:

$|0\rangle^{\otimes k}$) 간의 충실도를 측정하는 비용 함수를 제안했습니다.¹⁹

- **개념적 등가성:** 쓰레기 상태 측정 방법과 LS-SWAP은 모두 전체 출력 상태를 측정하는 것을 피합니다. 대신, 두 방법 모두 부분 시스템(subsystem)의 속성을 측정하여 성공적인 압축을 간접적으로 검증합니다. 쓰레기 상태 측정 방법은 버려진 정보가 사소한(trivial) 상태임을 보장하는 반면, LS-SWAP 방법은 유지된 정보가 정확함을 보장합니다. 이는 동일한 문제의 양면과 같으며, 둘 다 압축 과정을 간접적으로 검증하는 것을 목표로 합니다.
- **양자 머신러닝에서의 부분 공간 연산:** 잠재 공간에서 연산이나 분석을 수행하는 아이디어는 고전 및 양자 머신러닝 분야에서 흔히 사용됩니다. 최근 연구에서는 생성 모델(generative model)을 위해 고전 오토인코더의 잠재 공간에서 변분 회로를 사용하는 방법을 탐구하고 있습니다.²² LS-SWAP 방법은 정보가 풍부한 잠재 공간에 계산 자원을 집중시키는 유사한 철학을 적용합니다.
- **독창성:** 부분 또는 부분 공간 SWAP 테스트 자체가 근본적으로 새로운 개념은 아니지만, LS-SWAP 명세서에 기술된 바와 같이 이를 QAE 훈련의 주요 비용 함수로 적용하는 것은 기존 기술의 독창적이고 지능적인 변형으로 보입니다. 이는 (참조 큐비트 수를

줄임으로써) 보조 큐비트 없는 방법의 자원 효율성과 오토인코더 회로의 가장 중요한 부분에 집중하는 전략을 결합한 것입니다.

2.3. PennyLane에서의 구현 가능성 평가

명세서에 제안된 `ls_swap_circuit`은 PennyLane에서 직접적으로 구현 가능합니다.

- 핵심 함수:
 - `qml.CSWAP`: `qml.CSWAP` (Fredkin) 게이트는 PennyLane의 표준 라이브러리 연산입니다.²³ 잠재 큐비트와 참조 큐비트를 순회하며 `[control_qubit, i, n_data_qubits + i]`와 같은 올바른 와이어 매핑으로 `qml.CSWAP`를 적용하는 명세서의 로직은 정확하며 직접 구현할 수 있습니다.
 - 큐비트 관리: `n_data_qubits + n_latent + 1`의 큐비트 레이아웃은 잘 정의되어 있으며 PennyLane의 장치 프레임워크 내에서 쉽게 관리할 수 있습니다. 총 큐비트 수는 8개의 데이터 큐비트 전체에 대한 SWAP 테스트($8 + 8 + 1 = 17$ 큐비트 필요)보다 현저히 적어, 이 접근법의 자원 효율성을 보여줍니다.
 - 구현 가능성 결론: LS-SWAP 전략은 기술적으로 타당하며 표준 PennyLane 구성 요소를 사용하여 완전히 실현 가능합니다. 구현 로직은 명확하고 정확합니다.

2.4. 비판적 평가: 국소 비용 함수의 훈련 가능성 이점

LS-SWAP 방법의 가장 큰 장점은 훈련 가능성을 향상시키는 능력에 있습니다. 이는 국소 비용 함수를 사용함으로써 가능해집니다.

- **LS-SWAP** 비용 함수의 정의: 이 비용 함수는 단일 제어 큐비트에 대한 `qml.PauliZ`의 기댓값으로부터 파생됩니다. **CSWAP** 게이트가 이 제어 큐비트를 잠재 공간 및 참조 공간의 $2 * n_{\text{latent}}$ 큐비트와 얽히게 하지만, 측정 자체는 단일 큐비트에서 수행됩니다. 전체 `n_data_qubits` 시스템의 관점에서 볼 때, 이는 국소 관측량(local observable)에 해당합니다.
- 국소 비용 함수와 훈련 가능성의 연관성: 1.4절에서 확립된 바와 같이, 국소 관측량에 기반한 비용 함수는 황무지 평원에 훨씬 덜 취약합니다.
 - 이론적 증명: Cerezo 등의 연구는 회로 깊이가 $\mathcal{O}(\log n)$ 일 때 국소 비용 함수를 사용하면 기울기가 기껏해야 큐비트 수에 대해 *다항식적(polynomially)*으로만 사라짐을 보장한다는 것을 증명했습니다.¹⁶ 이는 전역 비용 함수의 지수적 소멸과 극명한 대조를 이룹니다. 이는 LS-SWAP이 DIFE보다 훨씬 더 훈련 가능성이 높을 것이라는 강력한 이론적 근거를 제공합니다.
 - 직관적 설명: 국소 측정은 깊은 회로에서 무작위 매개변수 초기화로 인해 생성될 수 있는 혼돈스럽고 고도로 얽힌 상태의 영향을 덜 받습니다. 비용 함수의 기울기에 대한 "정보"가 힐베르트 공간의 더 작은 부분에 집중되어 있어, 지수적으로 큰 전체 상태 공간에 걸쳐 "희석"되는 것을 방지합니다.¹⁴

이 분석을 통해 LS-SWAP 방법의 핵심적인 전략적 가치를 이해할 수 있습니다. 이 방법의 주된 "단점", 즉 실제 재구성 충실도가 아닌 대리 충실도를 측정한다는 점이 실제로는 가장 큰 전략적 이점이 됩니다. 이러한 타협은 국소 비용 함수의 사용을 가능하게 하며, 이는 결국 황무지 평원 문제를 피함으로써 확장 가능한 훈련의 잠재력을 열어줍니다. DIFE 방법은 전역 비용 함수로 인해 훈련 가능성 테스트를 통과하지 못합니다. 확장 가능한 QAE를 위해서는 다른 접근법이 필요합니다. 황무지 평원을 피하는 핵심은 국소 비용 함수를 사용하는 것이며, 이는 전체 상태를

국소적으로 측정할 수 없으므로 부분 시스템의 속성을 측정해야 함을 의미합니다. QAE 문헌은 쓰레기 큐비트를 측정하는 선례를 제공하며, 이는 쓰레기 부분 시스템에 대한 국소 측정입니다. LS-SWAP 명세서는 잠재 공간 부분 시스템의 충실도를 측정하는 대안을 제안하며, 이 또한 국소 측정입니다. 이 국소 측정(SWAP 테스트의 단일 제어 큐비트를 통해)은 이론적으로 잘 동작하는 기울기를 가질 것으로 예측되어 훈련 가능성을 보장합니다. 따라서 대리 측정 기준(잠재 공간 충실도)을 사용하기로 한 결정은 결함이 아니라, 측정의 이론적 순수성보다 훈련 가능성이라는 실용적 필요성을 우선시하는 의도적이고 지능적인 공학적 선택입니다. 이는 DIFE를 비실용적으로 만드는 근본적인 문제를 해결합니다.

3. 비교 분석 및 전략적 권장 사항

본 섹션에서는 개별 분석 결과를 종합하여 직접적인 비교를 제공하고 개발팀을 위한 실행 가능한 권장 사항을 제시합니다.

3.1. 자원 및 성능 상충 관계

아래 표는 기준 모델인 enhanced_qvae(전체 SWAP 테스트 가정), DIFE, LS-SWAP 전략 간의 주요 차이점을 명확하게 요약합니다. 이 비교는 각 방법론이 제시하는 복잡한 상충 관계를 효과적으로 전달하기 위해 설계되었습니다. 비교를 위한 핵심 지표는 자원 비용(큐비트 수), 측정의 본질(직접적 대 대리적), 그리고 그에 따른 성능 영향(훈련 가능성)입니다.

지표	enhanced_qvae (전체 SWAP)	DIFE 전략	LS-SWAP 전략
총 큐비트 수	$n_{data} + n_{data} + 1$ (예: 17)	n_{data} (예: 8)	$n_{data} + n_{latent} + 1$ (예: 11)
보조/참조 큐비트 수	$n_{data} + 1$ (예: 9)	0	$n_{latent} + 1$ (예: 3)
충실도 측정 방식	직접적 (전체 상태)	직접적 (재구성)	간접적 (잠재 공간 대리)
비용 함수 유형	전역 (Global)	전역 (Global)	국소 (Local)
주요 장점	실제 상태 충실도 측정	가장 큐비트 효율적, 우아함	확장 가능한 훈련 가능성, 자원 최적화
주요 단점	가장 높은 큐비트 오버헤드	황무지 평원 발생 위험 높음	실제 충실도가 아닌 대리 지표 측정

3.2. 핵심 이분법: 충실도 대 훈련 가능성

- **DIFE:** 측정 순수성의 경로: 이 전략은 오토인코더의 주요 기능, 즉 자신의 연산을 되돌릴 수 있는지에 대한 수학적으로 정확하고 직접적인 측정 방법을 제공합니다. 이는 목표 함수에 가장 충실한 측정 기준입니다. 그러나 이러한 전역 충실도 측정은 상당한 수의 큐비트에 대해 훈련 불가능한 최적화 환경을 초래할 가능성이 높다는 심각한 대가를 치릅니다.
- **LS-SWAP:** 실용적 훈련 가능성의 경로: 이 전략은 의도적인 타협을 합니다. 국소 비용 함수를 사용하는 대가로 간접적인 대리 성공 척도를 받아들입니다. 이러한 국소성은 황무지 평원을 완화하고 실용적이며 확장 가능한 훈련 알고리즘을 가능하게 하는 핵심입니다. 이 방법은 최상의 해결책을 완벽하게 측정하는 것보다 좋은 해결책을 찾는 것을 우선시합니다.

두 접근법 중 어느 것도 "틀렸다"고 할 수 없으며, 최적의 선택은 전적으로 프로젝트의 목표에 달려 있습니다. 소규모(예: 4-6 큐비트) 학술적 시연이나 개념 증명을 위해서는 DIFE의 우아함과 직접성이 선호될 수 있습니다. 반면, 규모를 확장하거나 실제 문제를 해결하려는 모든 응용 프로그램에서는 훈련 가능성에 초점을 맞춘 LS-SWAP이 훨씬 우수하고 실용적인 공학적 선택입니다.

3.3. 실험적 검증 및 개발 권장 사항

- 구현 진행: DIFE와 LS-SWAP 모두 잘 정립된 이론에 기반하고 있으므로 명세서에 따라 구현을 진행해야 합니다. 기술 명세서는 타당합니다.
- 황무지 평원 검증 연구 설계: 가장 중요한 다음 단계는 훈련 가능성에 대한 이론적 예측을 실험적으로 검증하는 것입니다. 다음과 같은 구성 요소를 포함하는 연구를 설계해야 합니다.
 1. 시스템 크기 확장: 다양한 $n_{\text{data_qubits}}$ 수(예: 4, 6, 8, 10, 12)에 대해 DIFE 및 LS-SWAP QAE를 모두 구현합니다.
 2. 훈련 실행: 각 크기에 대해 무작위 매개변수 초기화로부터 여러 번(예: 20-30회)의 훈련을 수행합니다.
 3. 데이터 수집: 최적화기의 각 반복 단계에서 비용 함수 값을 기록합니다.
 4. 분석:
 - 각 시스템 크기에서 DIFE와 LS-SWAP의 평균 비용 함수 대 반복 횟수 그래프를 그립니다.
 - 가설: DIFE 그래프는 작은 n 에 대해서는 성공적인 훈련을 보이지만, 큰 n 에 대해서는 평탄해져(정체되어) 황무지 평원을 나타낼 것입니다. LS-SWAP 그래프는 테스트된 모든 크기에서 일관된 수렴을 보여야 합니다.
 - 두 방법에 대해 초기화 시점의 기울기 분산을 n 의 함수로 계산합니다. DIFE의 분산은 지수적으로 감소해야 하며, LS-SWAP의 분산은 다항식적으로 감소해야 합니다.
- 향후 연구 - 하이브리드 접근법: 하이브리드 훈련 스케줄을 탐색할 것을 제안합니다. 예를 들어, 훈련 가능성이 더 높은 LS-SWAP 비용 함수로 훈련을 시작하여 매개변수를 "좋은" 영역으로 이동시킨 다음, 미세 조정을 위해 DIFE 비용 함수로 전환하는 방식입니다. 이는 두 접근법의 장점을 결합할 수 있는 잠재력을 가집니다.

결론

DIFE 및 LS-SWAP 명세서는 프로젝트의 QAE 프레임워크에 가치 있고 통찰력 있는 기여를 합니다. DIFE는 확립된 `compute-uncompute` 충실도 테스트의 우아하고 자원 효율적인 구현이며, LS-SWAP은 훈련 가능성이라는 중요한 과제를 우선시하는 SWAP 테스트의 영리하고 실용적인 변형입니다. 본 보고서의 핵심 발견은 DIFE의 측정 순수성과 LS-SWAP의 확장 가능성 사이에 존재하는 근본적인 상충 관계를 식별한 것입니다. 최종 권장 사항은 두 방법의 구현을 진행하고, 예측된 훈련 가능성 격차를 확인하기 위한 엄격한 실험적 테스트를 수행하여 향후 모든 QAE 개발의 전략적 방향을 설정하는 것입니다.

참고 자료

1. Exploring the Feasibility of Using Quantum Machine Learning to Detect Cryptocurrency Trading Anomalies By: Atharv Attri, Irvine - ThinkYou?!, 8월 24, 2025에 액세스, https://thinkyou.bayhonors.org/wp-content/uploads/BHS_Papers/AtharvAttri_ExploringTheFeasibility_.pdf
2. Biology and medicine in the landscape of quantum advantages | Journal of The Royal Society Interface, 8월 24, 2025에 액세스, <https://royalsocietypublishing.org/doi/10.1098/rsif.2022.0541>
3. ComputeUncompute (v0.39) | IBM Quantum Documentation, 8월 24, 2025에 액세스, https://quantum.cloud.ibm.com/docs/api/qiskit/0.39/qiskit.algorithms.state_fidelities.ComputeUncompute
4. ComputeUncompute (v0.43) | IBM Quantum Documentation, 8월 24, 2025에 액세스, https://quantum.cloud.ibm.com/docs/api/qiskit/0.43/qiskit.algorithms.state_fidelities.ComputeUncompute
5. ComputeUncompute - Qiskit Algorithms 0.3.1 - GitHub Pages, 8월 24, 2025에 액세스, https://qiskit-community.github.io/qiskit-algorithms/stubs/qiskit_algorithms.state_fidelities.ComputeUncompute.html
6. Overhead-constrained circuit knitting for variational quantum dynamics - arXiv, 8월 24, 2025에 액세스, <https://arxiv.org/html/2309.07857v3>
7. Ancilla-free implementation of generalized measurements for qubits embedded in a qudit space | Phys. Rev. Research, 8월 24, 2025에 액세스, <https://link.aps.org/doi/10.1103/PhysRevResearch.4.033027>
8. Ancilla-free continuous-variable SWAP test (Journal Article) | OSTI.GOV, 8월 24, 2025에 액세스, <https://www.osti.gov/pages/biblio/1887149>
9. Ancilla-free continuous-variable SWAP test - Quantum Journal, 8월 24, 2025에 액세스, <https://quantum-journal.org/papers/q-2022-09-08-800/>
10. arXiv:2303.12839v2 [quant-ph] 27 Mar 2023, 8월 24, 2025에 액세스, <https://arxiv.org/pdf/2303.12839v2/1000>
11. qml.adjoint — PennyLane 0.42.2 documentation, 8월 24, 2025에 액세스, <https://docs.pennylane.ai/en/stable/code/api/pennylane.adjoint.html>
12. qml.ops.op_math.Adjoint — PennyLane 0.42.2 documentation, 8월 24, 2025에 액세스,

- https://docs.pennylane.ai/en/stable/code/api/pennylane.ops.op_math.Adjoint.html
13. qml.Projector — PennyLane 0.42.2 documentation, 8월 24, 2025에 액세스, <https://docs.pennylane.ai/en/stable/code/api/pennylane.Projector.html>
 14. Alleviating barren plateaus with local cost functions | PennyLane ..., 8월 24, 2025에 액세스, https://pennylane.ai/qml/demos/tutorial_local_cost_functions
 15. Investigating and Mitigating Barren Plateaus in Variational Quantum Circuits: A Survey, 8월 24, 2025에 액세스, <https://arxiv.org/html/2407.17706v1>
 16. Cost-Function-Dependent Barren Plateaus in Shallow Quantum Neural Networks | Request PDF - ResearchGate, 8월 24, 2025에 액세스, https://www.researchgate.net/publication/338355374_Cost-Function-Dependent_Barren_Plateaus_in_Shallow_Quantum_Neural_Networks
 17. [2001.00550] Cost Function Dependent Barren Plateaus in Shallow Parametrized Quantum Circuits - arXiv, 8월 24, 2025에 액세스, <https://arxiv.org/abs/2001.00550>
 18. Cost function dependent barren plateaus in shallow parametrized ..., 8월 24, 2025에 액세스, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7979934/>
 19. arXiv:1612.02806v2 [quant-ph] 10 Feb 2017, 8월 24, 2025에 액세스, <https://arxiv.org/pdf/1612.02806>
 20. (PDF) Quantum autoencoders for efficient compression of quantum ..., 8월 24, 2025에 액세스, https://www.researchgate.net/publication/311514664_Quantum_autoencoders_for_efficient_compression_of_quantum_data
 21. Quantum autoencoders for efficient compression of quantum data - Harvard DASH, 8월 24, 2025에 액세스, <https://dash.harvard.edu/bitstreams/7312037e-9cab-6bd4-e053-0100007fdf3b/download>
 22. [2501.11174] Quantum Latent Diffusion Models - arXiv, 8월 24, 2025에 액세스, <https://arxiv.org/abs/2501.11174>
 23. qml.CSWAP — PennyLane 0.42.2 documentation, 8월 24, 2025에 액세스, <https://docs.pennylane.ai/en/stable/code/api/pennylane.CSWAP.html>
 24. Absence of Barren Plateaus in Quantum Convolutional Neural Networks | Phys. Rev. X, 8월 24, 2025에 액세스, <https://link.aps.org/doi/10.1103/PhysRevX.11.041011>