

양자 오토인코더를 위한 고급 회로 아키텍처: 데이터 임베딩 및 얽힘 구조 혁신 프레임워크

섹션 1: 양자 오토인코딩의 기초 원리

양자 오토인코더(Quantum Autoencoder, QAE)는 고전적인 오토인코더의 원리를 양자 시스템에 적용한 변형적 양자 알고리즘(variational quantum algorithm)입니다.² 하지만 이를 단순히 고전적 모델의 양자적 유사체로 보는 것은 그 잠재력을 축소하는 것입니다. QAE는 양자 컴퓨터에서 수행되는 고유한 정보 처리 과제로, 데이터의 핵심 특징을 양자 상태의 압축된 부분 공간에 학습시키는 것을 목표로 합니다.⁴

1.1 양자 오토인코더 패러다임

QAE의 핵심 목표는 훈련 가능한 파라미터 θ 를 갖는 압축 유니터리(compression unitary) $U_{enc}(\theta)$ 를 학습하는 것입니다. 이 유니터리는 데이터 임베딩 회로 $S(x)$ 에 의해 준비된 입력 상태 $|\psi_{in}\rangle = S(x)|0\rangle^{\otimes n}$ 에 작용합니다. 전체 시스템은 일반적으로 잠재(latent), 쓰레기(trash), 그리고 참조(reference) 큐비트의 세 부분으로 구성된 복합 시스템으로 매핑됩니다.⁶

QAE의 작동 원리는 정보의 선별적 분리에 있습니다. 예를 들어, 신용카드 사기 탐지 문제에서 '정상 거래' 데이터 클래스를 정의하는 핵심 정보는 잠재 큐비트 시스템에 집중시키고, 관련 없거나 노이즈에 해당하는 정보는 '쓰레기' 큐비트 시스템으로 강제로 분리하는 것입니다.¹ 이상적으로, 이 과정이 성공적으로 완료되면 쓰레기 큐비트의 상태는 입력 데이터와 무관한 최대 혼합 상태(maximally mixed state)가 되어야 합니다.⁴ 제공된 연구의

enhanced_qvae 모델은 $N_{TRASH_QUBITS} = 2$ 를 명시적으로 설정함으로써 이러한 정보 분리 개념을 아키텍처에 직접 구현하고 있습니다.¹

알고리즘의 최종 목표는 재구성 충실도(reconstruction fidelity)를 최대화하는 것입니다.

이는 잠재 시스템에서 재구성된 상태와 고정된 참조 상태(일반적으로 $|0\rangle^{\otimes n_L}$, 여기서 n_L 은 잠재 큐비트의 수) 사이의 중첩(overlap)으로 정의됩니다.⁴ 이 충실도는 모델의 성능을 평가하고 최적화하기 위한 손실 함수의 기초가 됩니다.

1.2 손실 함수와 최적화 환경

QAE의 훈련은 충실도 기반 손실 함수를 최소화하는 과정입니다. 제공된 연구 자료에서는 두 가지 주요 손실 함수가 사용되었습니다.

- **제곱 손실 (Squared Loss):** 표준 **angle** 모델에서는 $(1-\text{fidelity})^2$ 형태의 제곱 손실을 사용합니다.¹ 이는 고전적인 오토인코더에서 널리 사용되는 평균 제곱 오차(MSE)와 유사한 접근 방식입니다. 그러나 이 손실 함수는 충실도가 1에 가깝거나 0에 가까울 때 기울기가 0으로 수렴하는 경향이 있어, 최적화 과정에서 기울기 소실(vanishing gradients), 즉 배런 플래토(barren plateau) 현상을 유발할 수 있습니다.⁸
- **선형 손실 (Linear Loss):** 반면, SWAP 테스트를 사용하는 **enhanced_qvae** 모델은 $1-\text{fidelity}$ 형태의 선형 손실을 채택합니다.¹ 이 선택은 단순한 대안이 아니라, 최적화 환경을 개선하기 위한 의도적인 공학적 결정입니다.

이러한 손실 함수의 선택은 모델의 최종 성능에 지대한 영향을 미칩니다. **enhanced_qvae** 모델이 **G-Mean** 및 **F1-Score**와 같은 균형 잡힌 평가 지표에서 **angle** 모델을 압도적으로 능가하는 결과¹는 단순히 회로의 표현력이 높기 때문만은 아닙니다. 그 배경에는 최적화 전략의 우수성이 자리 잡고 있습니다.

SWAP 테스트는 두 양자 상태 간의 유사성을 측정하는 근본적인 양자 알고리즘으로⁹, 단일 큐비트의 파울리 기댓값 측정과 같은 간접적인 대리 지표가 아닌, 양자 상태 간의 충실도를 직접적으로 측정하는 정밀한 방법을 제공합니다.² 이 정밀한 충실도 측정값을 선형 손실 함수와 결합하면, 손실 함수의 기울기는 충실도

F 가 1에 가까워져도 0으로 소멸하지 않고 일정한 크기를 유지합니다. 반면, 제곱 손실 $(1-F)^2$ 의 기울기는 $-2(1-F) \frac{dF}{d\theta}$ 로, F 가 1에 접근함에 따라 빠르게 0으로 수렴합니다. 따라서 선형 손실은 훈련 막바지에 모델이 최적점에 더 가깝게 수렴하도록 돕고, 더 나은 분리 경계면을 학습할 수 있게 합니다. 결론적으로, **enhanced_qvae**의 뛰어난 성능은 표현력이 풍부한 안사츠(ansatz)와 더불어, SWAP 테스트와 선형 손실 함수의 시너지 효과에 기인한다고 분석할 수 있습니다. 이는 새로운 QAE 아키텍처를 제안할 때 회로 구조뿐만 아니라 측정 및 최적화 방식의 혁신도 동등하게 중요함을 시사합니다.

섹션 2: 참조 아키텍처 해체 및 혁신 벡터 식별

이 섹션에서는 제공된 연구의 두 가지 QAE 모델을 심층적으로 분석하여, 이들을 기반으로 아직 탐구되지 않은 혁신 방향을 도출합니다.

표 2.1: 참조 아키텍처 비교 분석

특성	QAE_Angle	Enhanced qVAE
큐비트 토폴로지	4 큐비트 (4 데이터)	13 큐비트 (8 데이터, 2 참조, 2 쓰레기, 1 제어)
데이터 임베딩 전략	AngleEmbedding (RY 회전)	병렬 임베딩 (2x 복제), 데이터 재업로딩, 교차 RY/RX 회전
변형 안사츠 구조	4개 층, 각 층은 RX, RY, RZ 회전	4개 층, 각 층은 RY, RZ 회전
얽힘 맵	순환(Circular) CNOT	순환(Circular) CNOT
파라미터 수	48	64
측정 프로토콜	단일 큐비트 Pauli-Z 기댓값	SWAP 테스트 (양자 충실도 측정)
손실 함수	제공 손실: $(1-F)^2$	선형 손실: $1-F$
주요 성능 (AUC)	0.8048	0.8660
주요 성능 (G-Mean)	0.564	0.760
주요 성능 (F1-Score)	0.485	0.792

2.1 표준 Angle QAE 분석

Angle QAE는 4개의 PCA(주성분 분석) 특징을 4개의 큐비트에 매핑하는 단순하고 직관적인 구조를 가집니다.¹ 데이터는

qml.AngleEmbedding을 통해 각 큐비트의 RY 회전각으로 인코딩됩니다. 변형 안사츠는 4개의 층으로 구성되며, 각 층은 큐비트별로 RX,RY,RZ 회전(큐비트당 3개의 파라미터)과 인접한 큐비트 간 순환 CNOT 얽힘 맵을 적용합니다. 이로 인해 총 학습 가능한 파라미터 수는 $4 \text{ (층)} \times 4 \text{ (큐비트)} \times 3 \text{ (파라미터/큐비트)} = 48$ 개가 됩니다.¹

이 모델의 성능은 '분리성 병목 현상(separability bottleneck)'이라는 한계를 명확히 보여줍니다. AUC-ROC 점수는 0.8048로 비교적 높아, 모델이 정상 샘플과 이상 샘플을 순위 매기는 데에는 어느 정도 성공했음을 나타냅니다.¹ 그러나 G-Mean(0.564)과 F1-Score(0.485)가 현저히 낮은 것은, 어떤 임계값을 선택하더라도 두 클래스를 명확하게 구분하는 결정 경계면을 찾는 데 실패했음을 의미합니다.¹

이러한 성능 불일치는 두 클래스에 대한 재구성 충실도 점수 분포가 상당히 겹쳐져 있음을 시사합니다. 그 근본 원인은 안사츠의 제한된 표현력(expressivity)에 있습니다.¹² 표현력이란 파라미터화된 양자 회로(PQC)가 힐베르트 공간을 얼마나 균일하게 탐색할 수 있는지를 측정하는 지표로, 모델의 잠재적 성능을 결정합니다.¹⁴ 단순한 각도 인코딩과 최근접 이웃 CNOT 얽힘의 조합은 고차원 힐베르트 공간에서 두 데이터 클래스를 분리하는 복잡하고 비선형적인 경계면을 학습하기에 불충분한 표현력을 가집니다. 이는 QAE 성능 향상을 위해 반드시 해결해야 할 핵심적인 실패 지점이며, 새로운 아키텍처 제안의 주된 동기가 됩니다.

2.2 Enhanced qVAE 분석

Enhanced qVAE는 13개의 큐비트를 사용하는 훨씬 복잡한 시스템으로, 성능 향상을 위해 여러 고급 기법을 도입했습니다.

- 병렬 임베딩 (**Parallel Embedding**): 4개의 특징을 두 번 복제하여 총 8개의 데이터 큐비트에 인코딩합니다.¹ 이는 데이터의 영향력을 양자 상태 공간에 더 넓게 분산시키는 효과를 가집니다.
- 데이터 재업로딩 (**Data Re-uploading**): 4개의 변형 층 각각에서 데이터를 반복적으로 인코딩합니다. 고전 신경망에서 입력 데이터가 여러 뉴런에 의해 반복적으로 처리되는 것에서 영감을 받은 이 기법은, 회로의 표현력을 기하급수적으로 높여 더 복잡한 함수를 근사할 수 있게 합니다.⁷
- 풍부한 파라미터화: 임베딩 시 교차적으로 RY/RX 회전을, 안사츠에서는 RY/RZ 회전을 사용하여 큐비트당 2개의 파라미터를 학습합니다. 총 파라미터 수는 $4 \text{ (층)} \times 8 \text{ (데이터 큐비트)} \times 2 \text{ (파라미터/큐비트)} = 64$ 개입니다.¹

- **고급 측정:** 2개의 참조, 2개의 쓰레기, 1개의 제어 큐비트를 사용하는 SWAP 테스트를 통해 양자 충실도를 직접 측정합니다.¹

이 모델은 아키텍처의 복잡성과 자원 사용량을 늘리는 것이 균형 잡힌 성능 지표의 극적인 향상으로 이어진다는 것을 명백히 보여줍니다 (**angle** 모델 대비 **G-Mean +34.7%**, **F1-Score +63.3%**).¹ 하지만 이러한 성능 향상은 막대한 자원 비용을 수반합니다. 큐비트 수는 3.2배, 훈련 시간은 2.0배 증가했습니다.¹

'큐비트당 AUC (AUC per Qubit)'라는 지표는 이러한 트레이드오프를 정량적으로 보여줍니다. **enhanced_qvae**는 이 지표에서 **-66.9%**의 효율성 감소를 보였습니다.¹ 이는 전체 성능은 높지만, 단위 양자 자원당 얻는 성능 이득은 오히려 낮다는 것을 의미합니다. 이는 양자 머신러닝 연구의 핵심 과제를 제시합니다: 어떻게

enhanced_qvae의 높은 성능을 달성하면서도 그에 따르는 엄청난 자원 비용을 줄일 수 있는가? 이 질문은 다음 섹션에서 제안할 새로운 아키텍처들의 근본적인 동기가 됩니다.

섹션 3: 제안 I - 향상된 상관관계 포착을 위한 고급 얽힘 구조

이 섹션에서는 참조 모델들의 주된 약점, 즉 복잡하고 장거리의 데이터 상관관계를 포착하기에 부적합한 단순한 최근접 이웃 얽힘 전략¹을 직접적으로 개선하는 방안을 제안합니다. PQC의 얽힘 생성 능력은 표현력과 함께 모델의 성능을 좌우하는 핵심 요소입니다.¹²

3.1 계층적 얽힘 안사츠 (Hierarchical Entanglement Ansatz, HEA)

- **개념:** 트리 텐서 네트워크(Tree Tensor Networks, TTN)¹⁷ 및 다중 스케일 얽힘 재규격화 안사츠(Multi-scale Entanglement Renormalization Ansatz, MERA)¹⁹에서 영감을 받은 이 안사츠는 로그 스케일로 증가하는 거리의 큐비트 쌍에 얽힘 게이트를 적용합니다. 이를 통해 모델은 지역적(local) 상관관계에서부터 전역적(global) 상관관계에 이르기까지 모든 규모의 특징 간 상호작용을 효율적으로 학습할 수 있습니다.²¹
- **구조 (8개 데이터 큐비트 기준):**
 - **1단계 (지역적):** CNOT 게이트를 인접한 쌍 (0,1), (2,3), (4,5), (6,7)에 적용합니다.
 - **2단계 (권역적):** CNOT 게이트를 한 칸 떨어진 쌍 (0,2), (1,3), (4,6), (5,7)에

적용합니다.

- **3단계 (전역적):** CNOT 게이트를 멀리 떨어진 쌍 (0,4), (1,5), (2,6), (3,7)에 적용하여 시스템 전체를 연결합니다.
- 이 패턴은 L개의 변형 층 각각에서 단일 큐비트 회전 게이트와 번갈아 가며 반복됩니다.
- **학술적 정당성:** 이 구조는 PCA 주성분처럼 계층적 중요도를 갖는 데이터에 특히 적합한 귀납적 편향(inductive bias)을 도입합니다. 초기 주성분은 전역적 정보를, 후기 주성분은 지역적 정보를 담는 경향이 있기 때문입니다. 순환 CNOT 구조¹에 비해 멀리 떨어진 큐비트 간에 정보가 전파될 수 있는 훨씬 효율적인 경로를 제공하여, 복잡한 데이터 상관관계를 더 효과적으로 학습할 수 있습니다.²²
- **파라미터 분석:** n개의 큐비트 시스템에서 L개의 층과 큐비트당 3개의 회전 게이트(RX,RY,RZ)를 사용하는 경우, 총 파라미터 수는 $P=L \times n \times 3$ 으로 angle 모델의 방식과 동일합니다. 혁신은 파라미터의 수가 아니라, 얽힘 구조를 통해 파라미터들이 만들어내는 비지역적(non-local) 효과와 그 배열 방식에 있습니다.

3.2 공분산 정보 기반 얽힘 (Covariance-Informed Entanglement, CIE)

- **개념:** 이는 얽힘 맵이 고정되어 있지 않고, 입력 데이터의 고전적인 상관관계 구조에 의해 결정되는 데이터 기반(data-driven) 또는 문제 인식(problem-aware) 접근 방식입니다.²³
- **구조:**
 1. 전처리 단계: 훈련 데이터의 고전적인 공분산 행렬, $\text{Cov}(X_{\text{train}})$ 을 계산합니다.
 2. 게이트 적용: 각 얽힘 층에서, 공분산의 절댓값 $|\text{Cov}(X_i, X_j)|$ 가 가장 큰 특징 쌍에 해당하는 큐비트 (i,j) 사이에 2-큐비트 게이트(예: CNOT 또는 RXX 게이트)를 적용합니다. 이 얽힘 맵은 훈련 내내 고정될 수도 있고(정적 방식), 주기적으로 재평가될 수도 있습니다(동적 방식).
- **학술적 정당성:** 이 방법은 문제 구조에 대한 사전 지식을 양자 회로에 직접 주입합니다.²⁵ 통계적으로 종속적인 특징을 나타내는 큐비트들 사이에 우선적으로 얽힘을 생성함으로써, 관련 있는 상관관계를 훨씬 빠르게 학습할 수 있는 잠재력을 가집니다. 이는 순환 CNOT 구조¹의 비효율적인 정보 전파에 대한 직접적인 대응책입니다.
- **파라미터 분석:** 단일 큐비트 회전 파라미터의 수는 $P_{\text{rot}}=L \times n \times 3$ 으로 유지됩니다. 만약 $R_{XX}(\theta)$ 와 같이 파라미터화된 2-큐비트 게이트를 사용한다면 추가적인 파라미터가 발생합니다. 한 층에 k개의 얽힘 게이트가 있다면, $P_{\text{ent}}=L \times k$ 개의 파라미터가 추가됩니다. 따라서 총 파라미터 수는 $P = L \times (3n + k)$

k)가 됩니다.

섹션 4: 제안 II - 하이브리드 및 학습 가능한 데이터 임베딩 계층

이 섹션은 정적인 AngleEmbedding¹과

enhanced_qvae의 단순한 재업로딩 방식¹을 넘어, 데이터 임베딩 과정 자체를 혁신하는 방안을 제안합니다. 데이터 임베딩 전략의 선택은 QAE의 성능에 결정적인 영향을 미칩니다.⁷

4.1 체비쇼프 타워 임베딩 (Chebyshev-Tower Embedding, CTE)

- **개념:** 모델이 비선형 관계를 학습하는 능력을 향상시키기 위해, 특징값 x_i 자체뿐만 아니라, 이의 학습 가능한 비선형 함수를 인코딩합니다. 이 함수를 구성하기 위해 체비쇼프 다항식(Chebyshev polynomials)과 같은 직교 다항식 기저를 사용합니다.
- **구조:** 큐비트 i 에 인코딩되는 특징 x_i 에 대해, 회전각은 단순히 x_i 가 아니라 $\phi(x_i, \vec{\alpha}) = \sum_{k=0}^M \alpha_k T_k(x_i)$ 가 됩니다. 여기서 T_k 는 k 차 체비쇼프 다항식이며, α_k 는 학습 가능한 파라미터입니다. 이는 일련의 단일 큐비트 회전으로 구현될 수 있습니다.
- **학술적 정당성:** 양자 신호 처리(Quantum Signal Processing, QSP)에서 차용한 이 기법은 회로가 입력 데이터의 최적 비선형 변환을 훈련 과정의 일부로서 학습하게 합니다.²⁶ QSP는 양자 상태에 임의의 다항식 변환을 적용할 수 있는 강력한 프레임워크를 제공합니다.²⁸ 이는 angle 모델¹의 고정된 RY 또는 RX 회전보다 훨씬 큰 유연성을 모델에 부여하며, 잠재적으로 훨씬 더 강력한 특징 맵(feature map)을 생성할 수 있습니다.
- **파라미터 분석:** n 개의 특징, 데이터 재업로딩을 포함하는 L 개의 층, 그리고 M 차 다항식 확장을 사용하는 경우, 이 임베딩 방식은 $P_{\text{embed}} = n \times (M+1)$ 개의 학습 가능한 파라미터를 도입합니다. 이 파라미터들은 안사츠 파라미터와는 별개입니다. 재업로딩을 사용하는 모델에서는 이 파라미터들이 각 층에서 사용됩니다. 다른 부분이 단순한 안사츠라고 가정할 때, 총 파라미터 수는 $P = n \times (M+1) + L \times n \times 30$ 이 됩니다.

4.2 학습 가능한 즉각적 양자 다항식 (Trainable Instantaneous Quantum Polynomial, IQP) 임베딩

- 개념: 전체 임베딩 블록 자체를 입력 데이터에 따라 조건부로 작동하는 학습 가능한 PQC(Parameterized Quantum Circuit)로 취급합니다. 이는 학습 가능한 양자 커널(trainable quantum kernel)을 구성하는 것과 유사하며²⁹, 모델이 복잡하고 얽혀있는 특징 맵을 학습할 수 있게 합니다.
- 구조: 데이터 벡터 x 에 대한 임베딩은 회로 $U_{\text{embed}}(x, \theta_{\text{emb}}) = U_{\text{train}}(\theta_{\text{emb}}) U_{\text{data}}(x)$ 에 의해 수행됩니다.
 - $U_{\text{data}}(x)$: 얽힘이 없는 데이터 인코딩 층입니다. 예를 들어, 각 큐비트 i 에 $RZ(x_i)$ 를 적용합니다.
 - $U_{\text{train}}(\theta_{\text{emb}})$: 학습 가능하고 얽힘을 생성하는 PQC입니다. 예를 들어, RY 회전 층과 완전 연결(fully-connected) CNOT 맵으로 구성될 수 있습니다.
- 학술적 정당성: 이 아키텍처는 데이터를 표현할 최적의 기저(basis)를 학습합니다.²⁹ AngleEmbedding이 최적이라고 가정하는 대신, 최상의 얽힌 표현을 스스로 찾아냅니다. 이는 enhanced_qvae의 병렬적이고 얽힘 없는 임베딩¹에 비해 표현력 측면에서 상당한 발전을 이룬 것입니다.
- 파라미터 분석: 학습 가능한 임베딩 블록이 L_{emb} 개의 층과 n 개의 큐비트를 갖는다고 가정합니다. 이 블록의 파라미터 수는 (큐비트당 3개의 회전을 가정할 때) $P_{\text{emb}} = L_{\text{emb}} \times n \times 3$ 입니다. 주 안사츠는 그 자체의 파라미터 $P_{\text{ansatz}} = L_{\text{ansatz}} \times n \times 3$ 을 가집니다. 따라서 총 파라미터 수는 $P = (L_{\text{emb}} + L_{\text{ansatz}}) \times n \times 3$ 이 됩니다.

섹션 5: 제안 III - 단기적 실행 가능성을 위한 자원 최적화 아키텍처

이 섹션은 고성능을 보이지만 자원 비효율적인 Enhanced qVAE¹의 문제에 정면으로 대응하여, 더 적은 양자 자원(큐비트 및 게이트)으로 높은 충실도를 달성하는 것을 목표로 하는 아키텍처를 제안합니다. NISQ 시대에는 큐비트 수와 회로 깊이가 가장 중요한 제약 조건입니다.¹²

5.1 상쇄 간섭 충실도 추정 (Destructive Interference Fidelity Estimation, DIFE)

- 개념: 이 제안은 `enhanced_qvae`의 SWAP 테스트에 필요한 모든 보조 큐비트(참조, 쓰레기, 제어)를 제거합니다.¹ 대신, 인코더 $U_{\text{enc}}(\theta)$ 와 그 역함수 $U_{\text{enc}}(\theta)^\dagger$ 를 순차적으로 적용한 후, 초기 상태인 $|0\dots 0\rangle$ 상태의 생존 확률을 측정하여 충실도를 추정하는 보조 큐비트 없는(ancilla-free) 방식을 사용합니다.³²
- 구조: 실행될 회로는 $U_{\text{circuit}} = U_{\text{enc}}(\theta)^\dagger S(x)^\dagger S(x) U_{\text{enc}}(\theta)$ 입니다. 비용 함수는 초기 상태에 대한 프로젝터의 기댓값, 즉 $1 - \langle 0\dots 0 | U_{\text{circuit}} | 0\dots 0 \rangle$ 을 기반으로 합니다.
- 학술적 정당성: 이는 큐비트 수와 회로 깊이 사이의 명확한 트레이드오프를 제시합니다. `enhanced_qvae`에서 사용된 5개의 보조 큐비트를 제거함으로써¹, 아키텍처는 단기적(near-term) 양자 장치에서 훨씬 더 실행 가능해집니다.³⁴ 그 대가는 회로 깊이가 두 배로 증가하여 결맞음(decoherence)에 더 취약해지는 것입니다. 이는 NISQ(Noisy Intermediate-Scale Quantum) 시대의 하드웨어에 대한 중요한 공학적 선택입니다.
- 파라미터 분석: 학습 가능한 파라미터의 수는 인코더 $U_{\text{enc}}(\theta)$ 의 파라미터 수와 동일합니다. 역함수는 새로운 파라미터를 도입하지 않기 때문입니다. 인코더가 P_{enc} 개의 파라미터를 가진다면, 총 파라미터 수는 단순히 $P = P_{\text{enc}}$ 가 됩니다.

5.2 큐비트 효율적 잠재 공간 SWAP 테스트 (Latent Space SWAP Test, LS-SWAP)

- 개념: SWAP 테스트의 직접적인 충실도 측정이라는 장점은 유지하면서 큐비트 오버헤드를 줄이는 하이브리드 접근 방식입니다. 전체 참조 상태를 준비하는 대신, 가장 중요한 잠재 공간 큐비트의 충실도만을 테스트합니다.
- 구조: 8개의 데이터 큐비트 시스템이 2개의 큐비트 잠재 공간(예: 큐비트 0과 1)으로 압축되는 경우, 이 두 큐비트에 대해서만 SWAP 테스트를 수행합니다.
 - 데이터 큐비트: 8개
 - 잠재 큐비트: 2개 (데이터 큐비트의 일부)
 - 참조 큐비트: 2개 (잠재 공간을 위함)
 - 쓰레기 큐비트: 0개 (나머지 6개의 데이터 큐비트가 암묵적으로 쓰레기 시스템이 됨)
 - 제어 큐비트: 1개
 - 총 큐비트 수: $8+2+1=11$ 개. 이는 `enhanced_qvae`에 필요한 13개보다 감소한 수치이면서도¹, 시스템의 가장 중요한 부분에 대한 직접적인 충실도 검사를 유지합니다.
- 학술적 정당성: 이는 실용적인 절충안입니다. SWAP 테스트가 좋은 손실 환경을 만드는 데 가치가 있다는 점을 인정하면서도⁹, 현재 하드웨어에서 큐비트 비용이 극심하다는 현실을 반영합니다. 가장 중요한 곳, 즉 압축된 잠재 상태에만 고정밀 측정 자원을 집중시킵니다.

- **파라미터 분석:** 인코더 회로의 파라미터 수는 변경되지 않습니다. 변화는 순전히 측정 토폴로지와 보조 큐비트 요구사항에만 있습니다.

섹션 6: 비교 프레임워크 및 종합

이 마지막 섹션에서는 제안된 모든 아키텍처를 종합하고, 이들의 적용을 위한 전략적 가이드를 제공합니다.

표 6.1: QAE 아키텍처 통합 프레임워크

아키텍처	핵심 혁신	큐비트 요구사항 (공식)	학습 파라미터 (공식)	목표 이점	잠재적 난제
Angle	기준선	n	$L \times n \times 3$	자원 효율성	분리성 병목, 낮은 표현력
Enhanced qVAE	복합적 개선	$n_{data} + n_{ref} + n_{trash} + 1$	$L \times n_{data} \times 2$	높은 표현력, 우수한 성능	높은 자원 비용, 확장성
HEA	계층적 얽힘	n	$L \times n \times 3$	향상된 상관관계 포착	하드웨어 라우팅 제약
CIE	데이터 기반 얽힘	n	$L \times (3n + k)$	빠른 학습, 사전 지식 주입	고전적 연산 오버헤드
CTE	학습 가능한 비선형 임베딩	n	$n(M+1) + L \times n \times 3$	극대화된 표현력	파라미터 수 증가, 배런 플래토
IQP Embedding	학습 가능한 얽힘 임베딩	n	$(L_{emb} + L_{ansatz}) \times n \times 3$	최적의 특징 맵 학습	매우 높은 파라미터 수

DIFE	보조 큐비트 없는 충실도 측정	n	Penc	자원 효율성 (큐비트)	회로 깊이 증가, 결맞음 오류
LS-SWAP	부분적 SWAP 테스트	$n_{data} + n_{laten}$ $t+1$	Penc	자원과 성능의 절충	최적의 잠재 공간 선택

6.1 전략적 권장 사항 및 향후 방향

결론적으로, 본 보고서에서 제안된 새로운 아키텍처들은 참조 모델들이 정의한 성능-자원 환경 내에서 다양한 전략적 위치를 점유합니다.¹

- **최대 성능 추구 (미래 지향적):** CIE와 CTE 같은 아키텍처는 높은 파라미터 수와 상당한 고전-양자 상호작용을 요구하지만, 자원이 제약이 아닐 때 최첨단 결과를 달성할 수 있는 잠재력을 가집니다. 이들은 **enhanced_qvae**의 성능을 뛰어넘어 QAE의 한계를 확장하는 데 사용될 수 있습니다.³⁵
- **NISQ 시대의 우위 확보 (현실적):** HEA, DIFE, LS-SWAP과 같은 아키텍처는 현재 가장 유망한 발전 경로를 제시합니다. 이들은 **enhanced_qvae**의 막대한 자원 비용 없이 **angle** 모델의 '분리성 병목 현상'을 개선하는 것을 목표로 합니다. 즉, 표현력과 자원 효율성 사이에서 새롭고 더 최적화된 균형점을 찾으려는 시도입니다.³⁶

향후 연구 방향으로서는 제안된 가설들을 실험적으로 검증하는 것이 필수적입니다. 예를 들어, 벤치마크 데이터셋에서 HEA와 표준 순환 얽힘 구조를 직접 비교하여, 얽힘 맵이 **G-Mean** 점수에 미치는 영향을 정량화하는 실험은 '분리성 병목 현상'의 원인에 대한 가설을 직접적으로 테스트할 수 있을 것입니다. 또한, 확산 모델과 같은 생성형 AI를 활용하여 데이터에 최적화된 양자 회로를 자동으로 설계하는 데이터 기반 접근법도 유망한 연구 방향이 될 수 있습니다.³⁷ 이러한 실험적 검증과 새로운 설계 방법론의 탐구를 통해 본 보고서에서 제안된 이론적 프레임워크는 실질적인 양자 이점을 향한 구체적인 로드맵으로 발전할 수 있을 것입니다.

참고 자료

1. 1월 1, 1970에 액세스,
2. (PDF) Quantum autoencoders for efficient compression of quantum data - ResearchGate, 8월 12, 2025에 액세스,
https://www.researchgate.net/publication/311514664_Quantum_autoencoders_for_efficient_compression_of_quantum_data
3. Quantum autoencoders for efficient compression of quantum data, 8월 12,

- 2025에 액세스, <https://arxiv.org/abs/1612.02806>
4. Quantum autoencoders for efficient compression of quantum data - DASH (Harvard), 8월 12, 2025에 액세스, <https://dash.harvard.edu/bitstreams/7312037e-9cab-6bd4-e053-0100007fdf3b/download>
 5. The Quantum Autoencoder - Qiskit Machine Learning 0.8.3, 8월 12, 2025에 액세스, https://qiskit-community.github.io/qiskit-machine-learning/tutorials/12_quantum_autoencoder.html
 6. Quantum circuit autoencoder | Phys. Rev. A - Physical Review Link Manager, 8월 12, 2025에 액세스, <https://link.aps.org/doi/10.1103/PhysRevA.109.032623>
 7. The role of data embedding in quantum autoencoders for improved anomaly detection, 8월 12, 2025에 액세스, <https://arxiv.org/html/2409.04519v1>
 8. barren plateaus in hybrid quantum-classical neural network, 8월 12, 2025에 액세스, <https://quantumcomputing.stackexchange.com/questions/39507/barren-plateaus-in-hybrid-quantum-classical-neural-network>
 9. Mastering Swap Test in Quantum Algorithms - Number Analytics, 8월 12, 2025에 액세스, <https://www.numberanalytics.com/blog/ultimate-guide-to-swap-test-in-quantum-algorithms>
 10. Swap Test: The Quantum Algorithm You Need to Know - Number Analytics, 8월 12, 2025에 액세스, <https://www.numberanalytics.com/blog/swap-test-quantum-algorithm-you-need-to-know>
 11. Swap test - Wikipedia, 8월 12, 2025에 액세스, https://en.wikipedia.org/wiki/Swap_test
 12. Expressibility, entangling power, and quantum average causal effect ..., 8월 12, 2025에 액세스, <https://link.aps.org/doi/10.1103/PhysRevA.111.042620>
 13. Expressibility and Entangling Capability of Parameterized Quantum Circuits for Hybrid Quantum-Classical Algorithms - Bohrium, 8월 12, 2025에 액세스, <https://www.bohrium.com/paper-details/expressibility-and-entangling-capability-of-parameterized-quantum-circuits-for-hybrid-quantum-classical-algorithms/812726014869241856-57008>
 14. Expressibility and Entangling Capability of Parameterized Quantum Circuits for Hybrid Quantum-Classical Algorithms | Request PDF - ResearchGate, 8월 12, 2025에 액세스, https://www.researchgate.net/publication/336517772_Expressibility_and_Entangling_Capability_of_Parameterized_Quantum_Circuits_for_Hybrid_Quantum-Classical_Algorithms
 15. Data re-uploading for a universal quantum classifier - ResearchGate, 8월 12, 2025에 액세스, https://www.researchgate.net/publication/339087158_Data_re-uploading_for_a_universal_quantum_classifier
 16. Data re-uploading for a universal quantum classifier - SciSpace, 8월 12, 2025에

엑세스,

<https://scispace.com/pdf/data-re-uploading-for-a-universal-quantum-classifier-snoil65ir7.pdf>

17. Mastering Tree Tensor Networks, 8월 12, 2025에 엑세스,
<https://www.numberanalytics.com/blog/mastering-tree-tensor-networks>
18. ACML 2020 Tutorial - Tensor Learning Team, 8월 12, 2025에 엑세스,
https://qibinzhao.github.io/ACML2020_Tutorial/
19. MERA in Quantum Information: A Deep Dive - Number Analytics, 8월 12, 2025에 엑세스,
<https://www.numberanalytics.com/blog/mera-quantum-information-deep-dive>
20. Simulating quantum circuits using the multi-scale entanglement renormalization ansatz | Phys. Rev. Research - Physical Review Link Manager, 8월 12, 2025에 엑세스, <https://link.aps.org/doi/10.1103/PhysRevResearch.7.013063>
21. Tensor networks for quantum machine learning - electronic library -, 8월 12, 2025에 엑세스, https://elib.dlr.de/196090/1/Rieser2023_TN4QML.pdf
22. Tree Tensor Network (TTN) Tutorial - pytket-cutensornet API documentation, 8월 12, 2025에 엑세스,
https://docs.quantinuum.com/tket/extensions/pytket-cutensornet/examples/ttn_tutorial.html
23. Enhanced natural parameterized quantum circuit | Phys. Rev. Research, 8월 12, 2025에 엑세스, <https://link.aps.org/doi/10.1103/PhysRevResearch.7.013221>
24. Variational Quantum Algorithms - Medium, 8월 12, 2025에 엑세스,
<https://medium.com/@qcgiitr/variational-quantum-algorithms-66367053a2f3>
25. Data-driven criteria for quantum correlations | Phys. Rev. A - Physical Review Link Manager, 8월 12, 2025에 엑세스,
<https://link.aps.org/doi/10.1103/PhysRevA.109.022405>
26. Quantum signal processing with the one-dimensional quantum Ising model | Phys. Rev. B, 8월 12, 2025에 엑세스,
<https://link.aps.org/doi/10.1103/PhysRevB.109.014306>
27. Quantum Signal Processing Algorithm and Its Applications - eScholarship.org, 8월 12, 2025에 엑세스, <https://escholarship.org/uc/item/1mq5b94m>
28. Function Fitting using Quantum Signal Processing | PennyLane ..., 8월 12, 2025에 엑세스, https://pennylane.ai/qml/demos/function_fitting_qsp
29. Quantum Kernel Training for Machine Learning Applications - Qiskit ..., 8월 12, 2025에 엑세스,
https://qiskit-community.github.io/qiskit-machine-learning/locale/fr_FR/tutorials/08_quantum_kernel_trainer.html
30. Training quantum kernels with quantum neural networks | Phys. Rev. Research, 8월 12, 2025에 엑세스, <https://link.aps.org/doi/10.1103/xphb-x2g4>
31. Optimizing Variational Quantum Algorithms with qBang: Efficiently Interweaving Metric and Momentum to Navigate Flat Energy Landscapes - arXiv, 8월 12, 2025에 엑세스, <https://arxiv.org/html/2304.13882v2>
32. Double-time contour quantum circuit for ancilla-free evaluation of the... | Download Scientific Diagram - ResearchGate, 8월 12, 2025에 엑세스,
<https://www.researchgate.net/figure/Double-time-contour-quantum-circuit-for->

- [ancilla-free-evaluation-of-the-overlap-cost_fig2_360388936](#)
33. [2303.00881] Achieving metrological limits using ancilla-free quantum error-correcting codes - arXiv, 8월 12, 2025에 액세스, <https://arxiv.org/abs/2303.00881>
 34. Ancilla-free continuous-variable SWAP test - Quantum Journal, 8월 12, 2025에 액세스, <https://quantum-journal.org/papers/q-2022-09-08-800/pdf/>
 35. Quantum Autoencoder for Multivariate Time Series Anomaly Detection - ResearchGate, 8월 12, 2025에 액세스, https://www.researchgate.net/publication/391120624_Quantum_Autoencoder_for_Multivariate_Time_Series_Anomaly_Detection
 36. [2012.09265] Variational Quantum Algorithms - arXiv, 8월 12, 2025에 액세스, <https://arxiv.org/abs/2012.09265>
 37. AI-Powered Diffusion Model Generates Quantum Circuits, Opens Path to Automated Quantum Programming, 8월 12, 2025에 액세스, <https://thequantuminsider.com/2025/07/01/ai-powered-diffusion-model-generates-quantum-circuits-opens-path-to-automated-quantum-programming/>